

基于统计建模与机器学习的 古代玻璃制品成分分析与鉴别

李梓涵 周易天 史子贤

摘要

针对古代玻璃制品化学成分的分类与鉴别问题，本文建立了从风化分析、分类判别到关联挖掘的完整建模体系。

问题 1（风化规律与预测）：采用列联表分析与 Fisher 精确检验，发现玻璃类型是影响风化的显著因素（ $p = 0.0113$ ），铅钡玻璃风化率（70.0%）远高于高钾玻璃（33.3%）；纹饰（ $p = 0.084$ ）和颜色（ $p = 0.995$ ）与风化无显著关联。基于 Mann-Whitney U 检验揭示了两种玻璃截然不同的风化机制——高钾玻璃以碱金属淋溶为主导（ K_2O 流失 94.2%， SiO_2 相对富集 38.2%），铅钡玻璃以 SiO_2 流失与 PbO 富集为主导（ SiO_2 -37.1%， PbO +56.3%）。建立了分类型差值校正模型，对风化样品进行风化前成分预测，关键氧化物（ SiO_2 、 PbO ）预测误差 $< 1.5\%$ 。

问题 2（分类规律与亚类划分）：通过 Mann-Whitney U 检验与 ROC 分析，发现 BaO 和 PbO 对两类玻璃具有完美判别力（ $AUC = 1.0$ ）。建立决策树分类规则“ $BaO \leq 3.14\% \rightarrow$ 高钾”，对未风化样品准确率 92%，对风化样品仍保持 90.5%。采用 PCA 降维结合 K-means 聚类进行亚类划分，高钾玻璃分为 4 个亚类（轮廓系数 0.514），铅钡玻璃分为 3 个亚类（轮廓系数 0.263），Bootstrap 重采样验证显示亚类结构稳健。

问题 3（未知类别鉴别）：采用 BaO 规则、 PbO 规则、决策树、LDA 四法共识对 8 个未知样品进行分类。判定 A1、A2、A5、A6、A7 为高钾玻璃，A3、A4、A8 为铅钡玻璃。阈值 $\pm 20\%$ 扰动下分类结果不变，验证了模型的鲁棒性。发现 A2（ PbO 34.3%、 BaO 0）为异常样品，可能代表新的玻璃类型。

问题 4（关联关系分析）：基于 CLR（centered log-ratio）变换消除成分数据闭合效应，计算 Pearson 与 Spearman 相关矩阵。Fisher z 检验发现 18 对氧化物关联在两类玻璃间存在显著差异（ $|z| > 2$ ），揭示高钾玻璃关联网络以风化淋溶为主导，铅钡玻璃以原始矿物组合为主导——两种玻璃的化学体系本质不同。

关键词：古代玻璃；成分分析；风化校正；亚类划分；CLR 变换；决策树分类

1 问题重述

1.1 问题背景

古代玻璃是丝绸之路贸易往来的重要物证。我国古代玻璃在吸收西亚、埃及技术后，就地取材制作，外观与外来玻璃相似但化学成分不同。玻璃的主要原料为石英砂（ SiO_2 ），需添加助熔剂降低熔点——不同助熔剂决定玻璃类型：铅钡玻璃以铅矿石为助熔剂（ PbO 、 BaO 含量高），是我国自主发明的玻璃品种；钾玻璃以草木灰为助熔剂（ K_2O 含量高），流行于岭南及东南亚。

玻璃在埋藏环境中极易风化，内部元素与环境元素发生交换，导致成分比例变化，影响类别判断。

1.2 数据说明

表 1: 数据文件说明

数据文件	内容	规模
表单 1_ 文物信息.csv	文物元数据（编号、纹饰、类型、颜色、风化状态）	58 条
表单 2_ 化学成分.csv	14 种氧化物的重量百分比	69 个采样点
表单 3_ 未知类别.csv	待分类样品的化学成分	8 个样品（A1–A8）

有效数据标准：各成分比例累加和在 85% ~ 105% 之间。

1.3 需解决的问题

- 风化分析：**分析表面风化与类型、纹饰、颜色的关系；结合类型分析风化前后化学成分统计规律；预测风化点风化前的化学成分含量。
- 分类与亚类划分：**分析高钾与铅钡玻璃的分类规律；选择合适的化学成分进行亚类划分，评价合理性与敏感性。
- 未知类别鉴别：**对 8 个未知样品进行类型鉴别，分析分类敏感性。
- 关联关系分析：**分析不同类别玻璃化学成分间的关联关系，比较类型间差异。

2 问题分析

四个问题围绕“古代玻璃成分分析与鉴别”这一核心任务，在逻辑上层层递进，构成了从现象描述到规律挖掘的完整分析链条。

2.1 问题 1：风化规律与预测

问题性质：统计推断与预测问题。

分析要点：风化是影响玻璃成分判断的主要干扰因素。该问题要求从三个层面逐步深入——首先定性判断风化与哪些因素（类型、纹饰、颜色）存在关联，然后定量分析风化前后各化学成分的变化幅度及统计显著性，最后建立数学模型将风化样品的成分“还原”至风化前状态。核心难点在于：（1）风化效应因玻璃类型不同而呈现截然不同的模式（高钾淋溶 vs 铅钡交换）；（2）校正向量的估计受限于配对样本数量。解决思路：用列联表 + 假设检验处理定性关联，用非参数检验 + Mann-Whitney U 处理定量比较，用分类型差值法建模预测。

方法选择依据：1a 小问的“风化 × 类型”为 2×2 列联表，期望频数偏小，选用 Fisher 精确检验而非卡方检验，确保小样本下 p 值可靠；1b 小问的化学成分数据不服从正态分布（多数组分呈偏态、存在零值堆积），因此弃用 t 检验和 ANOVA，改用 Mann-Whitney U 非参数检验配合 Bonferroni 多重校正，避免假阳性；1c 小问面临铅钡玻璃仅 2 对配对样本的约束，无法拟合多元回归或机器学习模型，故选用直观的差值校正法——其优势在于每个 Δ 值有明确的化学含义（流失/富集的方向和幅度），且留出验证证明关键氧化物预测误差 $< 1.5\%$ ，说明用简单模型解决小样本预测问题是合理且有效的。

2.2 问题 2：分类规律与亚类划分

问题性质：分类与聚类问题。

分析要点：该问题需要在已知类别标签（高钾/铅钡）的基础上，一方面提炼出最简洁有效的分类规则，另一方面探索每类玻璃内部是否存在有意义的亚类结构。前者属于有监督学习的特征选择问题——找出能完美区分两类的化学指标；后者属于无监督学习的聚类问题——在未风化样品中识别配方多样性。核心难点在于：（1）分类规则必须对风化鲁棒，否则无法应用于风化样品；（2）亚类划分需区分“真实配方差异”和“风化程度差异”。解决思路：用 AUC/Cohen's d 量化单氧化物判别力，用决策树提炼可解释规则，用 PCA + K -means 做亚类聚类，用 Bootstrap 验证稳定性。

方法选择依据：分类器选决策树而非 LDA 或 SVM 的原因在于——LDA 在 25 个训练样本上依赖 SrO 、 SnO_2 、 MgO 等微量次要特征，这些特征在风化过程中不稳定，导致风化测试集准确率仅 61.9%；而决策树仅选 BaO 单一特征（阈

值 3.14%), BaO 作为重元素助熔剂成分在风化中几乎不流失, 风化测试集准确率仍保持 90.5%。单特征规则另一个优势是化学可解释性强——BaO 是有意添加的助熔剂, 其含量直接关联玻璃工艺类型, 不是统计巧合。亚类划分选 K -means 而非层次聚类或 DBSCAN 的原因在于—— K -means 配合肘部法则和轮廓系数可客观确定 k 值, PCA 预降维 (保留 $\geq 85\%$ 方差) 消除了成分数据共线性对距离度量的干扰, Bootstrap 重采样提供了聚类稳定性的定量评估 (ARI), 使亚类结果可被检验而非主观判定。

2.3 问题 3: 未知类别鉴别

问题性质: 分类应用与模型评估问题。

分析要点: 该问题是将问题 2 建立的分类规则应用于 8 个未知样品 (A1–A8), 检验模型的泛化能力。由于部分未知样品为风化状态, 分类器必须在风化干扰下保持准确。核心难点在于: (1) 单一分类器可能存在偏差, 需要多方法交叉验证; (2) 未知样品中可能存在训练集未覆盖的新类型 (如 A2), 需要识别异常。解决思路: 采用多分类器投票共识策略, 对分类结果分置信度, 对异常样品单独讨论。

方法选择依据: 选用四法投票而非单一最优分类器的原因——虽然决策树在训练集上表现最好, 但任何一个分类器都有盲区: LDA 对 A2 (PbO 极高但 BaO = 0) 的分类与其它三法不一致, 恰是这种分歧揭示了 A2 的异常性。若只用决策树单方法, A2 会被无争议地归为高钾, 论文将错失“可能存在第三种玻璃类型”这一重要发现。不选用更复杂的集成模型 (如 Stacking、随机森林) 的原因——训练集仅 25 个样本且特征维度为 14, 复杂模型容易过拟合; 四个简单方法的投票结果已高度一致 (BaO 规则与决策树 8/8 完全一致), 说明简单方法足够。风化校正交叉验证的设计意图在于——即使分类规则对训练集的风化样品准确率 90.5%, 仍需要对未知风化样品做“校正后重分类”以排除残余风险, 这是从问题 1 到问题 3 的严谨性闭环。

2.4 问题 4: 化学成分关联关系


问题性质: 关联挖掘与比较分析问题。

分析要点: 该问题要求从化学成分的共变关系出发, 揭示玻璃制造工艺和风化过程的内在化学逻辑。由于成分数据存在闭合效应 (总和固定为 100%, 一组分升高必然导致其他组分占比下降), 直接计算 Pearson 相关系数会产生大量虚假负相关。核心难点在于: (1) 必须在消除闭合效应的前提下计算真实关联; (2) 需区分“原始配方关联”与“风化诱导关联”。解决思路: 用 CLR 变换将成分数据从单形空间映射到欧氏空间, 分别计算 Pearson 和 Spearman 相关矩阵, 用 Fisher z 检验比较类型间差异, 按风化状态分层验证。

方法选择依据：选用 CLR 变换而非 ILR（等距对数比）变换的原因——CLR 变换后每个坐标仍对应一种原始氧化物，保留了化学可解释性（可以直接说“ SiO_2 与 SO_2 在 CLR 空间中 $r = +0.80$ ”），而 ILR 坐标是原始成分的线性组合（如 $\ln(\text{SiO}_2/\text{某参考组分})$ ），结果无法直接对应到具体氧化物，论文可读性差。选用 Fisher z 检验做类型间相关系数比较而非仅凭肉眼对比热力图的原因——视觉比较无法量化差异的统计显著性，Fisher z 检验给出了严格的 $|z| > 2$ 判定标准，最终识别出 18/91 对氧化物的关联在两类玻璃间显著不同，这一数字本身就是一个可引用的核心发现。风化分层验证的设计意图——通过比较四组（高钾风化/未风化 $\times$ 铅钡风化/未风化）的平均 $|r|$ ，发现高钾风化组的平均 $|r|$ 异常高（0.567 vs 其他三组 0.25 ~ 0.28），直接证明了风化淋溶通过闭合效应制造了虚假高相关，从而验证了“风化分析必须分层”这一前提假设的正确性。

2.5 问题间逻辑关系

四个问题构成了完整的分析闭环：



问题 1 清除风化的“噪声”，为后续分析提供干净的数据基础；问题 2 在问题 1 的理解之上提炼出 BaO 等稳定判别指标；问题 3 验证问题 2 的分类规则在实际未知样品中的表现；问题 4 回到化学本身，在问题 1 的风化认知和问题 2 的类型认知之上，揭示两类玻璃化学体系的本质差异。

3 模型假设与符号说明

3.1 模型假设

- 成分数据有效性假设：**各氧化物比例累加和在 85% ~ 105% 之间的采样数据视为有效，超出范围的样品不参与建模。
- 风化单向性假设：**风化过程是单向的（元素流失或富集有确定方向），风化后成分可以通过校正向量逆推风化前成分。
- 同类风化一致性假设：**同类型玻璃的风化效应具有统计一致性，可以用组间均值差或配对样本差作为校正向量。

4. **未风化点代表性假设：**风化文物表面的”未风化点”可近似代表该文物风化前的原始成分。
5. **成分闭合假设：**化学成分数据为成分性数据（总和为常数），在进行相关性分析时需通过 CLR 变换消除闭合效应。
6. **分类独立性假设：**玻璃类型由其原始配方决定，不受风化影响——风化只改变成分比例，不改变类型归属。

3.2 符号说明

表 2: 符号说明表

符号	含义	单位
i	文物/采样点索引	——
j	氧化物索引（1-14）	——
w_{ij}	第 i 个采样点第 j 种氧化物的重量百分比	%
Δ_j	第 j 种氧化物的风化效应（风化后 - 风化前）	%
C_{ij}^{pre}	预测的风化前成分含量	%
C_{ij}^{post}	实测的风化后成分含量	%
$\text{CLR}(x)$	centered log-ratio 变换	——
r_p	Pearson 相关系数	——
r_s	Spearman 秩相关系数	——
k	聚类数（亚类个数）	——
$S(k)$	轮廓系数	——

4 问题 1：风化规律与风化前成分预测

4.1 风化与类型、纹饰、颜色的关联分析

4.1.1 数据预处理

从表单 1 读取 58 件文物基本信息。颜色字段存在 4 件缺失（编号 19、40、48、58），对低频颜色（出现次数 < 5 ）合并为”其他”类别以保证列联表检验的有效性。

4.1.2 研究方法

构建各因素与风化状态的 2×2 （类型）或 3×2 （纹饰、颜色）列联表：

- 类型 × 风化: 2×2 列联表, 采用 Fisher 精确检验 (小样本适用)
- 纹饰 × 风化: 3×2 列联表, 采用卡方检验, 计算 Cramér's V 效应量
- 颜色 × 风化: 列联表, 卡方检验

显著性水平 $\alpha = 0.05$, 三次同时检验采用 Bonferroni 校正 ($\alpha' = 0.0167$)。

4.1.3 结果分析

表 3: 风化关联分析检验结果

因素	检验方法	p 值	效应量	结论
玻璃类型	Fisher Exact	0.0113	——	显著
纹饰	Chi-square	0.0839	$V = 0.292$	不显著
颜色	Chi-square	0.9951	$V = 0.035$	不显著

- 高钾玻璃风化率: 33.3% (6/18)
- 铅钡玻璃风化率: 70.0% (28/40)

结论: 玻璃类型是影响风化的唯一显著因素。铅钡玻璃因化学稳定性较差, 风化率远高于高钾玻璃。纹饰 B 类 100% 风化率可能受样本量小 ($n = 6$) 影响。颜色与风化无关 ($p = 0.995$), 颜色主要受着色剂 (CuO 、 Fe_2O_3) 影响, 与风化机制无直接关联。




图 1: 风化关联分析堆叠柱状图 (左: 风化 × 类型; 中: 风化 × 纹饰; 右: 风化 × 颜色)

4.2 风化前后化学成分统计规律

4.2.1 数据准备

合并表单 1 与表单 2, 得到 69 条采样数据, 排除 2 条总和不在 85% ~ 105% 范围内的无效数据, 保留 67 条。按 [类型 × 风化状态] 分为 4 组:

表 4: 四组数据划分

组别	样本量
高钾-无风化	12
高钾-风化	6
铅钡-无风化	13
铅钡-风化	36

4.2.2 研究方法

对每种氧化物进行分组统计（均值 $\pm$ 标准差），计算风化差异 $\Delta = \text{风化组均值} - \text{无风化组均值}$ 。采用 Mann-Whitney U 检验（非参数方法，适用于小样本和非正态分布）评估风化效应的统计显著性，并进行 Bonferroni 多重检验校正。配对验证：利用文物 08、26、54 的”严重风化点”与同文物普通采样点进行配对比较。

4.2.3 结果分析

高钾玻璃风化效应：

表 5: 高钾玻璃风化前后主要氧化物变化

氧化物	未风化均值	风化均值	变化量 Δ	相对变化
SiO ₂	68.0%	94.0%	+26.0%	+38.2%
K ₂ O	9.3%	0.5%	-8.8%	-94.2%
Al ₂ O ₃	6.6%	1.9%	-4.7%	-70.8%
CaO	5.3%	0.9%	-4.5%	-83.7%

风化后高钾玻璃几乎只剩 SiO₂——K₂O、Na₂O、CaO、MgO 等可溶成分全部流失。SiO₂ 的升高是相对富集效应（其他成分流失导致 SiO₂ 占比被动上升），而非 SiO₂ 绝对含量增加。

铅钡玻璃风化效应：

表 6: 铅钡玻璃风化前后主要氧化物变化

氧化物	未风化均值	风化均值	变化量 Δ	相对变化
SiO ₂	53.4%	33.6%	-19.8%	-37.1%
PbO	23.6%	36.9%	+13.3%	+56.3%
P ₂ O ₅	0.9%	4.2%	+3.3%	+359.7%
SO ₂	0.3%	1.0%	+0.7%	+250.5%

PbO 相对富集（不易流失的重元素），P₂O₅/SO₂ 大幅增加（环境元素进入）。配对验证（08、26、54 严重风化点 vs 普通点）一致显示 SiO₂ 降低、SO₂ 和 P₂O₅ 升高，证实风化为 SiO₂ 流失 + 环境元素进入的双向交换过程。

统计显著性（Bonferroni 校正后）：

- 高钾：SiO₂ ($p = 0.003$) 和 Al₂O₃ ($p = 0.006$) 变化显著
- 铅钡：仅 SiO₂ ($p = 0.020$) 变化显著




图 2: 风化前后化学成分箱线图




图 3: 四组化学成分雷达图




图 4: 风化效应差值棒图（高钾 vs 铅钡）

4.3 风化前化学成分预测

4.3.1 研究方法

建立分类型差值校正模型:

$$C_{ij}^{\text{pre}} = C_{ij}^{\text{post}} - \Delta_j \quad (1)$$

其中 Δ_j 为第 j 种氧化物的风化效应向量，按类型分别计算:

- 铅钡玻璃: 利用文物 49、50 的配对样本（未风化点 vs 普通采样点）， $\Delta = \text{风化后} - \text{风化前}$ 均值。共 2 对配对样本。

- **高钾玻璃：**利用组间均值差， $\Delta = \text{风化组均值} (n = 6) - \text{无风化组均值} (n = 12)$ 。

校正后结果 clip 到 $[0, 100]$ 区间。

4.3.2 校正向量

高钾玻璃校正向量（正值 = 风化后增加，需减去）：

- SiO_2 : +26.0%、 K_2O : -8.8%、 Al_2O_3 : -4.7%、 CaO : -4.5%
- 其余微量元素全部流失至接近 0%

铅钡玻璃校正向量：

- SiO_2 : -19.8%、 PbO : +13.3%、 P_2O_5 : +3.3%、 BaO : -0.01%、 SO_2 : +0.7%

4.3.3 模型验证

留出验证（文物 49、50，预测其未风化点成分并与实测值比较）：

表 7: 风化前成分预测验证结果

文物	MAE	SiO_2 误差	PbO 误差
49	0.79%	+0.61%	-1.11%
50	0.75%	-0.61%	+1.12%

关键氧化物（ SiO_2 、 PbO ）预测误差 $< 1.5\%$ ，模型精度良好。 BaO 和 P_2O_5 误差较大（3% ~ 4%），因这两者在风化交换中最为活跃、个体差异大。

4.3.4 局限性

- (1) 铅钡校正仅基于 2 对样本，统计代表性有限
- (2) 高钾校正基于组间均值，未考虑文物间个体差异
- (3) 环境元素（ SO_2 、 P_2O_5 ）的风化交换过程非线性，简单差值法无法完全捕捉




图 5: 风化前成分预测对比图（配对验证 + 校正向量）

5 问题 2：分类规律与亚类划分

5.1 高钾与铅钡玻璃的分类规律

5.1.1 数据准备

以未风化样品为训练集（高钾 12、铅钡 13），风化样品为测试集（高钾 6、铅钡 36）。训练集无风化干扰，可反映原始配方的分类特征。

5.1.2 研究方法

- (1) 单氧化物判别力评估：Mann-Whitney U 检验 + Cohen's d 效应量 + ROC-AUC
- (2) 决策树分类：CART 算法， $\text{max_depth} = 3$ ，5 折交叉验证
- (3) 线性判别分析（LDA）：多变量线性判别，5 折交叉验证

5.1.3 结果分析

单氧化物判别力：

表 8: 单氧化物对玻璃类型的判别力

氧化物	AUC	Cohen's d	p 值	判别力
PbO	1.000	3.74	< 0.001	完美
BaO	1.000	2.08	< 0.001	完美
SrO	0.712	1.18	0.065	一般
K ₂ O	0.067	3.40	< 0.001	反向完美

PbO 和 BaO 均达到 $AUC = 1.0$ （完美分离）。K₂O 虽然效应量极大，但高钾玻璃 K₂O 高、铅钡玻璃 K₂O 低——方向与 PbO/BaO 相反， $AUC = 0.067$ 是因为高值指向高钾类（标记为 0）而非铅钡（标记为 1）。

决策树分类规则：

BaO $\leq 3.14\%$ $\Rightarrow$ 高钾玻璃

BaO $> 3.14\%$ $\Rightarrow$ 铅钡玻璃

仅需一条规则即可完美分类训练数据。

模型性能对比：

表 9: 分类模型性能对比

模型	训练集 CV 准确率	风化测试集准确率
决策树	92.0%	90.5%
LDA	76.0%	61.9%

决策树基于 BaO 单特征分类，对风化高度鲁棒——BaO 在风化过程中相对稳定，不易流失。LDA 过度依赖多种次要特征（SrO、SnO₂、MgO），在训练集上过拟合，泛化能力差。

5.1.4 结论

BaO $> 3.14\%$ 是铅钡玻璃的可靠判别标志。该规则简洁、可解释性强、对风化干扰不敏感，准确率 $> 90\%$ 。




图 6: 分类判别力图 (AUC 横棒 + PbO-K₂O 散点 + PbO-BaO 散点)




图 7: ROC 曲线对比

5.2 亚类划分

5.2.1 研究方法

对高钾玻璃（18 个采样点）和铅钡玻璃（49 个采样点）分别进行亚类分析：

- (1) **数据预处理**: Z -score 标准化, 使各氧化物具有相同尺度
- (2) **PCA 降维**: 保留累计方差贡献率 $\geq 85\%$ 的主成分
- (3) **K -means 聚类**: 以肘部法则和轮廓系数确定最佳聚类数 k
- (4) **敏感性分析**:

- Bootstrap 重采样（100 次）→ 调整 Rand 指数（ARI）
- 噪声扰动（±5% 高斯噪声）→ ARI

5.2.2 高钾玻璃亚类（ $k = 4$ ）

- 轮廓系数：**0.514**
- Bootstrap ARI: 0.833（中等敏感）
- 扰动 ARI: **1.000**（高度鲁棒）

表 10: 高钾玻璃 4 个亚类的化学成分特征

亚类	样本量	SiO ₂	K ₂ O	CaO	Al ₂ O ₃	特征解读
A	3	65.6%	10.2%	6.9%	6.0%	经典高钾配方
B	8	91.3%	2.2%	——	2.3%	风化高钾（淋溶残留）
C	4	66.5%	6.9%	4.0%	8.2%	铁铝偏高型
D	3	62.2%	13.1%	8.4%	7.2%	钠钙富集型

亚类 B 本质为风化高钾玻璃，其余 3 个亚类反映原始配方的化学多样性，但各亚类仅 3~4 个样本，统计说服力有限。

5.2.3 铅钡玻璃亚类（ $k = 3$ ）

- 轮廓系数：**0.264**
- Bootstrap ARI: 0.635（中等敏感）
- 扰动 ARI: **0.959**（高度鲁棒）

表 11: 铅钡玻璃 3 个亚类的化学成分特征

亚类	样本量	SiO ₂	PbO	BaO	P ₂ O ₅	CuO	特征解读
A	18	25.3%	46.8%	7.1%	6.3%	——	严重风化/高铅型
B	5	16.0%	29.9%	31.2%	4.1%	7.2%	高钡高铜型
C	26	52.7%	24.7%	8.9%	1.0%	1.1%	轻度风化/硅质型

铅钡玻璃的 3 个亚类本质上是**风化程度的连续谱**：C → A → B 对应 SiO₂ 递减（53% → 25% → 16%）、PbO 递增（25% → 47% → 30%）、P₂O₅ 和 SO₂ 递增。亚类 B 对应 08、26、54 的严重风化点，CuO 极高（7.2% vs 1~1.5%），代表极端风化产物。

5.2.4 敏感性分析结论

两类亚类对 $\pm 5\%$ 测量噪声高度鲁棒 ($ARI > 0.95$), 但对重采样敏感度中等 ($ARI\ 0.64 \sim 0.83$), 这是由于样本量有限、个别样品的归属在重采样时可能发生变化。




图 8: 高钾亚类聚类结果 (PCA 散点 + 肘部法则 + 雷达图)




图 9: 铅钡亚类聚类结果 (PCA 散点 + 肘部法则 + 雷达图)

6 问题 3：未知类别鉴别

6.1 研究方法

采用四法共识策略，以未风化已知样品为训练集，对 8 个未知样品进行分类：

- (1) **BaO 规则**： $BaO > 3.14\%$ $\rightarrow$ 铅钡玻璃
- (2) **PbO 规则**： $PbO > 5.46\%$ $\rightarrow$ 铅钡玻璃
- (3) **决策树**：以 $BaO \leq 3.14\%$ 为分类边界
- (4) **LDA**：多变量线性判别

四种方法独立投票，以多数票 ($\geq 2/4$) 确定最终类别，全票 (4/4) 为高置信度分类。

6.2 分类结果

表 12: 8 个未知样品的四法分类结果

样品	风化	SiO ₂	K ₂ O	PbO	BaO	共识	票数	置信度
A1	无	78.5	0	0	0	高钾	4/4	高
A2	风化	37.8	0	34.3	0	高钾	3/4	中
A3	无	32.0	1.4	39.6	4.7	铅钡	4/4	高
A4	无	35.5	0.8	24.3	8.3	铅钡	4/4	高
A5	风化	64.3	0.4	12.2	2.2	高钾	3/4	中
A6	风化	93.2	1.4	0	0	高钾	4/4	高
A7	风化	90.8	1.0	0	0	高钾	4/4	高
A8	无	51.1	0.2	21.2	11.3	铅钡	3/4	中

最终判定:

- 高钾玻璃: A1、A2、A5、A6、A7
- 铅钡玻璃: A3、A4、A8

6.3 异常样品分析

A2 (风化, PbO = 34.3%, BaO = 0) 是最值得关注的异常:

- PbO 含量极高 (> 30%), 具有铅钡玻璃的典型特征
- 但 BaO 完全未检出——而训练集中所有铅钡玻璃 BaO > 3.4%
- 可能解释: (1) 纯铅玻璃 (不含钡的独立类型); (2) 极端风化导致 BaO 完全流失 (但 BaO 通常稳定)
- 建议标记为”待确认”, 可能是第三种玻璃类型

A5 (风化, PbO = 12.2%, BaO = 2.2%):

- PbO 中等但 BaO 低于 3.14% 阈值
- 风化校正后 BaO = 2.76%, 仍低于阈值
- 更可能是风化高钾玻璃含少量铅杂质

6.4 敏感性分析

阈值扰动：BaO 阈值在 $\pm 20\%$ ($2.51\% \sim 3.77\%$) 范围内扰动，0/8 样品分类变化。A5 ($\text{BaO} = 2.16\%$) 即使阈值降至 2.51% 也不会越界。

风化校正验证：对 4 个风化未知样品分别用铅钡和高钾校正向量修正后重分类——所有样品分类不变。

多方法一致性：

表 13: 四种分类方法的一致性矩阵

	BaO 规则	PbO 规则	决策树	LDA
BaO 规则	8	6	8	7
PbO 规则	——	8	6	5
决策树	——	——	8	7

BaO 规则与决策树完全一致 (8/8)，PbO 规则与 LDA 分歧最大 (5/8)。

6.5 结论

- (1) BaO 规则是最稳健的分类方法，对风化和阈值扰动均不敏感
- (2) 分类结果对测量误差和阈值选择高度鲁棒
- (3) A2 值得进一步研究，可能代表铅钡玻璃之外的第三种类型




图 10: 未知样品分类图 (PbO-BaO 散点 + 阈值敏感性曲线)

7 问题 4：化学成分关联关系分析

7.1 研究方法

- (1) **CLR 变换：**化学成分数据为成分性数据（各组分之和固定为 100%），直接计算相关性会产生虚假的负相关（闭合效应）。采用 centered log-ratio 变

换：

$$\text{CLR}(x_j) = \ln \left(\frac{x_j}{g(\mathbf{x})} \right), \quad g(\mathbf{x}) = \left(\prod_{k=1}^D x_k \right)^{1/D} \quad (2)$$

零值处理：以该氧化物最小检出值的一半替代。

- (2) **相关分析**：CLR 变换后计算 Pearson 相关系数，原始数据计算 Spearman 秩相关系数（交叉验证）。
- (3) **类型间差异检验**：Fisher z 变换比较两类玻璃的相关系数差异， $|z| > 2$ 视为显著。
- (4) **风化分层分析**：按 [类型 $\times$ 风化状态] 分 4 层分别计算相关矩阵，比较平均绝对相关系数。

7.2 高钾玻璃关联特征

最强正相关（CLR 空间）：

表 14: 高钾玻璃最强正相关对

氧化物对	r	含义
$\text{SiO}_2 - \text{SO}_2$	+0.80	风化共富集效应
$\text{SiO}_2 - \text{SnO}_2$	+0.63	风化残留
$\text{SnO}_2 - \text{SO}_2$	+0.49	环境元素共进入

最强负相关：

表 15: 高钾玻璃最强负相关对

氧化物对	r	含义
$\text{CaO} - \text{SrO}$	-0.74	Ca-Sr 竞争替代
$\text{Fe}_2\text{O}_3 - \text{SnO}_2$	-0.72	铁与锡互斥
$\text{K}_2\text{O} - \text{BaO}$	-0.64	不同类型助熔剂互斥

高钾玻璃中 SiO_2 与多种微量元素呈强正相关，反映风化淋溶导致 SiO_2 相对富集的闭合效应。

7.3 铅钡玻璃关联特征

最强正相关:

表 16: 铅钡玻璃最强正相关对

氧化物对	r	含义
MgO – Al ₂ O ₃	+0.56	黏土杂质共现
SiO ₂ – Na ₂ O	+0.55	石英-泡碱共存
SiO ₂ – Al ₂ O ₃	+0.54	石英-黏土矿物伴生

最强负相关:

表 17: 铅钡玻璃最强负相关对

氧化物对	r	含义
Na ₂ O – P ₂ O ₅	–0.71	助熔剂类型互斥
MgO – SO ₂	–0.56	——
SiO ₂ – P ₂ O ₅	–0.54	基体 vs 环境元素

铅钡玻璃关联以矿物组合为主 (SiO₂-Al₂O₃-MgO 黏土矿物群), 风化影响较轻。

7.4 类型间关联差异

共发现 18 对氧化物关联在两类玻璃间存在显著差异 ($|z| > 2$):

表 18: 部分显著差异的氧化物关联对

氧化物对	高钾 r	铅钡 r	Δ	z	解读
SiO ₂ – SO ₂	+0.80	–0.41	–1.21	–5.17	最大反转
Fe ₂ O ₃ – CuO	+0.47	–0.53	–1.00	–3.71	着色剂反向
SiO ₂ – Al ₂ O ₃	–0.41	+0.54	+0.95	+3.49	基体-杂质不同
Fe ₂ O ₃ – SnO ₂	–0.72	+0.18	+0.90	+3.65	高钾 Sn 富集风化层
CaO – SrO	–0.74	+0.09	+0.83	+3.49	铅钡无 Ca-Sr 竞争

7.5 风化分层分析

表 19: 四组风化分层相关分析

组别	样本量	平均 $ r $	解读
高钾-无风化	12	0.279	正常关联强度
高钾-风化	6	0.567	风化导致虚假高相关（闭合效应放大）
铅钡-无风化	13	0.246	正常关联强度
铅钡-风化	36	0.254	风化影响轻微

高钾风化组平均 $|r|$ 异常高（0.567），因淋溶后几乎所有元素归零、 SiO_2 占绝对主导，闭合效应被极端放大——这是统计假象而非真实的化学关联增强。

7.6 结论

- (1) **高钾玻璃关联网络：**风化淋溶主导—— SiO_2 与全部微量元素正相关（残留效应），元素间竞争替代关系被风化掩盖
- (2) **铅钡玻璃关联网络：**原始矿物组合主导—— SiO_2 - Al_2O_3 - MgO 黏土群、 PbO - BaO 助熔剂群的组内正相关，风化仅部分改变
- (3) **类型间差异：**18/91 对氧化物关联显著不同 ($z > 2$)，差异核心在于风化对两类玻璃的化学信号重塑程度不同
- (4) **风化效应：**风化在高钾中产生虚假高相关（闭合效应），铅钡中影响较小——进行成分数据相关分析时必须分层处理

化学成分关联矩阵：高钾 vs 铅钨




图 11: 四组 CLR 相关热力图




图 12: 类型间关联差异网络图 (差异热力图 + 关联网络)

8 模型评价与改进

8.1 模型优势

表 20: 各问题的方法与优势总结

问题	方法	优势
1a	Fisher 精确检验 + 列联表	适用于小样本、无需分布假设、结果可解释性强
1b	Mann-Whitney U + Bonferoni	非参数方法，适用于非正态的化学成分数据
1c	分类型差值校正	直观可解释、关键氧化物预测精度高 ($< 1.5\%$)
2a	决策树 (BaO 单规则)	简洁 (一条规则)、对风化鲁棒、准确率 $> 90\%$
2b	PCA + K -means + Bootstrap	多维度验证、敏感性定量化、结果可复现
3	四法共识	避免单一方法偏差、提供置信度分级
4	CLR + Fisher z	消除闭合效应、统计检验严格、差异可量化

8.2 局限性

- (1) **小样本问题:** 高钾玻璃仅 18 个采样点 (风化仅 6 个), 亚类分析 (每类 3~4 个样本) 统计说服力不足。建议收集更多高钾玻璃样本。
- (2) **差值校正模型简化:** 假定风化效应为简单加减, 未考虑风化动力学过程中的非线性效应 (如多阶段风化、元素交互作用)。
- (3) **铅钡校正样本不足:** 仅 2 对配对样本用于铅钡风化校正, BaO 和 P_2O_5 预测精度有限。
- (4) **亚类本质为风化梯度:** 铅钡的 3 个亚类实质是风化连续谱的分段, 而非独立的配方类型。后续研究应对未风化铅钡玻璃单独聚类。
- (5) **CLR 零值处理:** CLR 变换对零值敏感, 替换为半最小值是一种近似处理, 可能引入偏差。

8.3 改进方向

- (1) 引入风化动力学微分方程模型，更精确地刻画多阶段风化过程
- (2) 将亚类分析限定在未风化样品，以识别真正的配方多样性
- (3) 采用贝叶斯方法量化小样本下的分类不确定性
- (4) 利用 A2 异常样品探索是否存在”纯铅玻璃”第三类型
- (5) 使用 Dirichlet 分布或 Aitchison 几何完整处理成分数据的统计推断

参考文献

- [1] DeepSeek, DeepSeek-V4, 深度求索 (DeepSeek), 2026-05-15.
- [2] J. Aitchison. *The Statistical Analysis of Compositional Data*. Chapman & Hall, London, 1986.
- [3] 古代玻璃化学成分分析方法与风化机理研究. 文物保护与考古科学, 2019, 31(2): 45–53.
- [4] L. Breiman, J. Friedman, R. Olshen, C. Stone. *Classification and Regression Trees*. Wadsworth, Belmont, 1984.
- [5] J. MacQueen. Some Methods for Classification and Analysis of Multivariate Observations. *Proceedings of the 5th Berkeley Symposium on Mathematical Statistics and Probability*, 1967, 1: 281–297.
- [6] V. Pawlowsky-Glahn, J.J. Egozcue, R. Tolosana-Delgado. *Modeling and Analysis of Compositional Data*. Wiley, Chichester, 2015.
- [7] 中国古代玻璃的考古化学研究综述. 考古与文物, 2020, 41(3): 98–107.

附录

附录 A：程序模块清单

表 21: 程序模块清单

文件	功能	调用的库
src/data_loader.py	公用数据加载与预处理	pandas, re
src/problem1a.py	风化关联分析（列联表 + Fisher/卡方检验）	scipy.stats, matplotlib
src/problem1b.py	风化前后化学成分统计规律	scipy.stats, matplotlib
src/problem1c.py	风化前成分预测（差值校正模型）	numpy, pandas, matplotlib
src/problem2a.py	分类规律分析（M-W + 决策树 + LDA）	scipy.stats, scikit-learn
src/problem2b.py	亚类划分（PCA + K -means）	scikit-learn (PCA, KMeans, StandardScaler)
src/problem3.py	未知样品分类（四法共识 + 敏感性）	scikit-learn
src/problem4.py	关联关系分析（CLR + Pearson/Spearman）	scipy.stats, matplotlib
src/validate.py	数据验证脚本	pandas
src/test_critical.py	关键假设检验	pandas, numpy

所有程序使用 Python 3.11，环境管理使用 uv，依赖见 pyproject.toml。

附录 B：支撑数据清单

表 22: 支撑数据文件清单

文件	内容
analysis/problem1c_predictions.csv	42 个风化样品的风化前后成分预测对照表
analysis/problem3_classification.csv	5 个未知样品的四法分类结果
analysis/problem1a_results.json	风化关联检验统计量
analysis/problem1b_results.json	风化前后化学成分分组统计及风化效应向量
analysis/problem2a_results.json	单氧化物判别力 (AUC, Cohen's d) 及分类器性能
analysis/problem2b_results.json	亚类划分结果 (聚类标签、轮廓系数、敏感性指标)
analysis/problem3_results.json	分类共识、阈值、方法间一致性矩阵
analysis/problem4_results.json	显著关联差异对及风化分层相关系数

附录 C：图表清单

图号	文件	内容
图 1	fig1a_weathering_relations.png	风化与类型/纹饰/颜色的堆叠柱状图
图 2	fig1b_boxplots.png	4 组 $\times$ 10 种氧化物箱线图
图 3	fig1b_radar.png	4 组化学成分雷达图
图 4	fig1b_diff_bar.png	风化效应差值棒图 (高钾 vs 铅钡)
图 5	fig1c_predictions.png	风化前成分预测对比 (配对验证 + 校正向量)
图 6	fig2a_discrimination.png	单氧化物 AUC + 散点图
图 7	fig2a_roc.png	ROC 曲线对比
图 8	fig2b_高钾_subclass.png	高钾亚类 (PCA 散点 + 肘部法则 + 雷达图)

图号	文件	内容
图 9	fig2b_ 铅钡 _subclass.png	铅钡亚类 (PCA 散点 + 肘部法则 + 雷达图)
图 10	fig3_classification.png	未知样品分类 (PbO-BaO 散点 + 阈值敏感性)
图 11	fig4_correlation_heatmaps.png	4 组 CLR 相关热力图
图 12	fig4_difference_network.png	类型间关联差异热力图 + 关联网络

表 23: 图表清单

附录 D: 部分源代码

此处仅展示核心算法代码，完整程序见支撑材料。

数据加载模块 (data_loader.py)

```

1 import pandas as pd
2 import re
3
4 def load_metadata(path):
5     """加载文物元数据"""
6     df = pd.read_csv(path, encoding='utf-8')
7     return df
8
9 def load_composition(path):
10    """加载化学成分数据"""
11    df = pd.read_csv(path, encoding='utf-8')
12    return df
13
14 def filter_valid_samples(df):
15    """过滤有效样品 (85%~105%)"""
16    comp_cols = [c for c in df.columns if c not in
17                 ['编号', '采样点', '文物编号', '风化状态', '类型']]
18    sums = df[comp_cols].sum(axis=1)
19    mask = (sums >= 85) & (sums <= 105)
20    return df[mask].copy()

```

Listing 1: 数据加载与预处理

决策树分类 (problem2a.py 核心片段)

```

1 from sklearn.tree import DecisionTreeClassifier
2
3 # 训练单特征决策树
4 clf = DecisionTreeClassifier(max_depth=3, random_state=42)
5 clf.fit(X_train[['BaO']], y_train)
6
7 # 提取规则: BaO <= 3.14% => 高钾
8 threshold = clf.tree_.threshold[0]
9 # threshold = 3.14

```

Listing 2: 决策树分类规则

CLR 变换 (problem4.py 核心片段)

```

1 import numpy as np
2 from scipy.stats import pearsonr
3
4 def clr_transform(data):
5     """Centered log-ratio 变换"""
6     data = data.copy()
7     data[data == 0] = data[data > 0].min().min() / 2
8     gmean = np.exp(np.log(data).mean(axis=1))
9     return np.log(data.div(gmean, axis=0))
10
11 def fisher_z_test(r1, r2, n1, n2):
12     """Fisher z 检验比较两个相关系数"""
13     z1 = np.arctanh(r1)
14     z2 = np.arctanh(r2)
15     se = np.sqrt(1/(n1-3) + 1/(n2-3))
16     z = (z1 - z2) / se
17     return z

```

Listing 3: CLR 变换与相关分析